

Day 2 cross validation

Sadeel Ardah

cross validation

Learning objectives :-

2.1 what cross validation ✓

2.2 How K-fold works (k=5) ✓

2.3 cross_val_score ✓

2.4 stratified k-fold for classification ✓

2.1 what cross validation

وتكون على

Training Data
↳ Train
↳ Test

المشكلة كانت بالبيانات كنا نحل

one validation score ، يمكننا ان نأخذ واحد من البيانات ك Validation set 20% من مجموعة سهلة لأنه أخذنا نفس جزء واحد من البيانات Validation مقدار 20% Validation split (1) بهر عن

(K-validation split) فنحن لو كان عندي 100 Training rows $K=5$ ينقسم 100 Training rows

- Fold 1
- Fold 2
- Fold 3
- Fold 4
- Fold 5

1 Fold ببساطة هو جزء من البيانات يبقى لو عندي 100 Training rows و $K=5$ ينقسمهم بالتساوي

Fold 1 = 20 rows
Fold 2 = 20 rows
Fold 3 = 20 rows
Fold 4 = 20 rows
Fold 5 = 20 rows

- طب بنعمل بها 5 Model بنرب المودل 5 مرات بس في كل مرة برب فيها Model بغير ال Fold ونستخدم Validation فنحن .

- استعن بالله .

2.2 How K-fold works (k=5)

Round	Train	Validation	F
Round 1	Fold 2, Fold 3, Fold 4, Fold 5	Fold 1	[val] [Train] [Train] [Train] [Train]
Round 2	Fold 1, Fold 3, Fold 4, Fold 5	Fold 2	[Train] [val] [Train] [Train] [Train]
Round 3	Fold 1, Fold 2, Fold 4, Fold 5	Fold 3	[Train] [Train] [val] [Train] [Train]
Round 4	Fold 1, Fold 2, Fold 3, Fold 5	Fold 4	[Train] [Train] [Train] [val] [Train]
Round 5	Fold 1, Fold 2, Fold 3, Fold 4	Fold 5	[Train] [Train] [Train] [Train] [val]

Round 1 → Fold 1 → F1 = 0.54
Round 1 → Fold 2 → F1 = 0.58
Round 1 → Fold 3 → F1 = 0.55
Round 1 → Fold 4 → F1 = 0.60
Round 1 → Fold 5 → F1 = 0.57

5 diff validation scores

unlucky, lucky Average F1 = 0.568 لوحة متوسطه
Average across 5 different validation folds نصرتنا
more stable

* انما نعمل model عند مربيها واحد فقط

اللهم صل وسلم وبارك على سيدنا وحبيبنا
ومفتيها محمد (صلى الله عليه وسلم).

2.3 cross_val_score

يَاي سترحاته بالسابق كان يدوي لكن مكتبة
scikit-learn
cross_val_score()

فعل ما زلت Loop ممتلئ
from sklearn.model_selection import cross_val_score

scores = cross_val_score(
model,

x_train,

y_train,

cv=5,

scoring='f1') ← 5-Fold cross-validation

استخدم المقياس
F1-score

مجموع array نتيجه كل fold

ونحن نحسب mean ∈ scores.mean() ونحسب
standard deviation (std) ∈ scores.std()

Low std → more stable

- High mean + Low std ⇒ Model قوي ومستقر
- High mean + High std ⇒ Model قوي لكن غير مستقر
- Low mean + High std ⇒ Model ضعيف وغير مستقر
- Low mean + Low std ⇒ Model ضعيف ومستقر

Mean: متوسط الأداء لكل fold عالي: قوي، منخفض: ضعيف

Std: مقدار اختلاف النتائج عن بعضها وكل ما كان أقل كل ما كان Model أكثر استقراراً

- سبحان الله والحمد لله

24 stratified k-fold for classification

Classification Dataset Problem :- تحليل عيني

1000 rows

class 0 → 900 rows

class 0 = 90%

class 1 → 100 rows

class 1 = 10%

Imbalanced ← Data Case

الآن بيانا Plain K-Fold 5-Fold cross-validation ← المشكلة هون مع ال
لو قسمنا البيانات بشكل ما بحافظ على نسبة ال classes فمكن نطلع د Fold
مختلفة جداً مثلاً :-

Fold 1

Fold 2

Fold 3

class 0 → 95%

class 0 → 82%

class 0 → 91%

class 1 → 5%

class 1 → 18%

class 1 → 9%

هون ال Validation Fold فيه توزيع مختلف وهذا اللي ممكن يخلي

Fold 1 → F1 → عالي

Fold 2 → F1 → منخفض

Fold 3 → F1 → متوسط

مش بيس بسبب ال Quality الخاصة
بال Model اعنا بسبب توزيع ال classes
المتغير

الحل :- Stratified K-Fold

وظيفةنا : بتحاول تحافظ على نفس ال Class proportions داخل كل Fold

فإذا ال Dataset الأصلية كانت 90% class 0 , 10% class 1

فكل Fold ه يكون تقريباً :

Fold 1 → 90% / 10%

Fold 2 → 90% / 10%

Fold 3 → 90% / 10%

Fold 4 → 90% / 10%

Fold 5 → 90% / 10%

الخلاصة

Original Dataset

90% / 10%

↓

Stratified K-Fold

↓

Fold 1 → ~90% / 10%

Fold 2 → ~90% / 10%

Fold 3 → ~90% / 10%

Fold 4 → ~90% / 10%

Fold 5 → ~90% / 10%

original class balanced
in every fold

- الحمد لله

```
from sklearn.model_selection import cross_val_score
```

وإلي السخدمنا ال Stratified K Fold
* لما زعل cross validation ال ال sklearn ،
Classifier بتطبق ال stratification تلقائي .
فدركان ال Model Random Forest Classifier
ال Classifier بتطبق ال stratification تلقائي

* الطريقة الثانية اكتبها بشكل صريح

Note

K-Fold

↓

k folds يقسم البيانات إلى

Stratified K-Fold

↓

k folds يقسم البيانات إلى

+

Class proportions يحافظ تقريبًا على

Fold داخل كل

```
from sklearn.model_selection import StratifiedKFold
```

```
cv = StratifiedKFold(  
    n_splits=5  
)
```

```
scores = cross_val_score(  
    model,  
    X_train,  
    y_train,  
    cv=cv,  
    scoring="f1"  
)
```

ناتج:-

